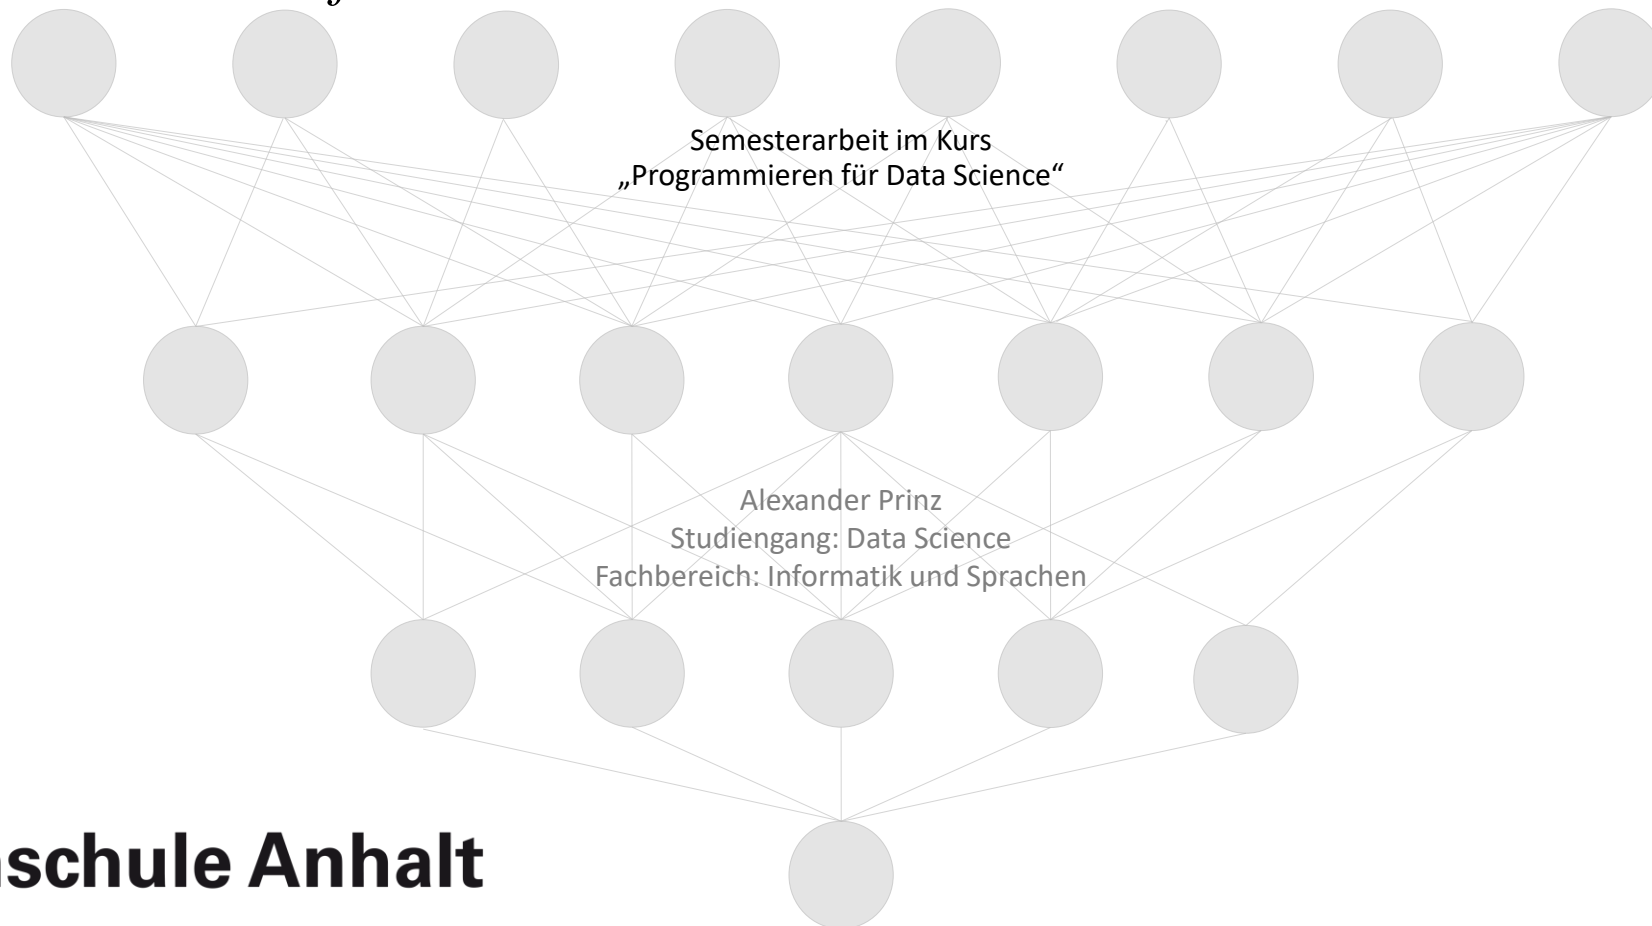


*Stofftransportmodellierung im hydrogeologischen Kontext
auf Basis eines künstlichen neuronalen Netzes*



Hochschule Anhalt

Anhalt University of Applied Sciences



- Motivation
 - Beispielszenario zur Anwendung von Stofftransportmodellierung im Grundwasserbereich
- Methoden
 - Konventionelle Methode und ihr Nutzen als Trainingsdatenquelle
 - numerische Lösung der Stofftransportgleichung
 - exemplarische Lösung der Stofftransportgleichung als Animation
 - Implementierung des Solvers und des semistochastischen Permeabilitätsfeldgenerators
 - Künstliches neuronales Netz als mögliche alternative Methode
 - Parametrisierung und Topologie
- Ergebnisse
 - Präsentation/Diskussion einiger exemplarischer Ergebnisse
- Fragen und Antworten

Motivation

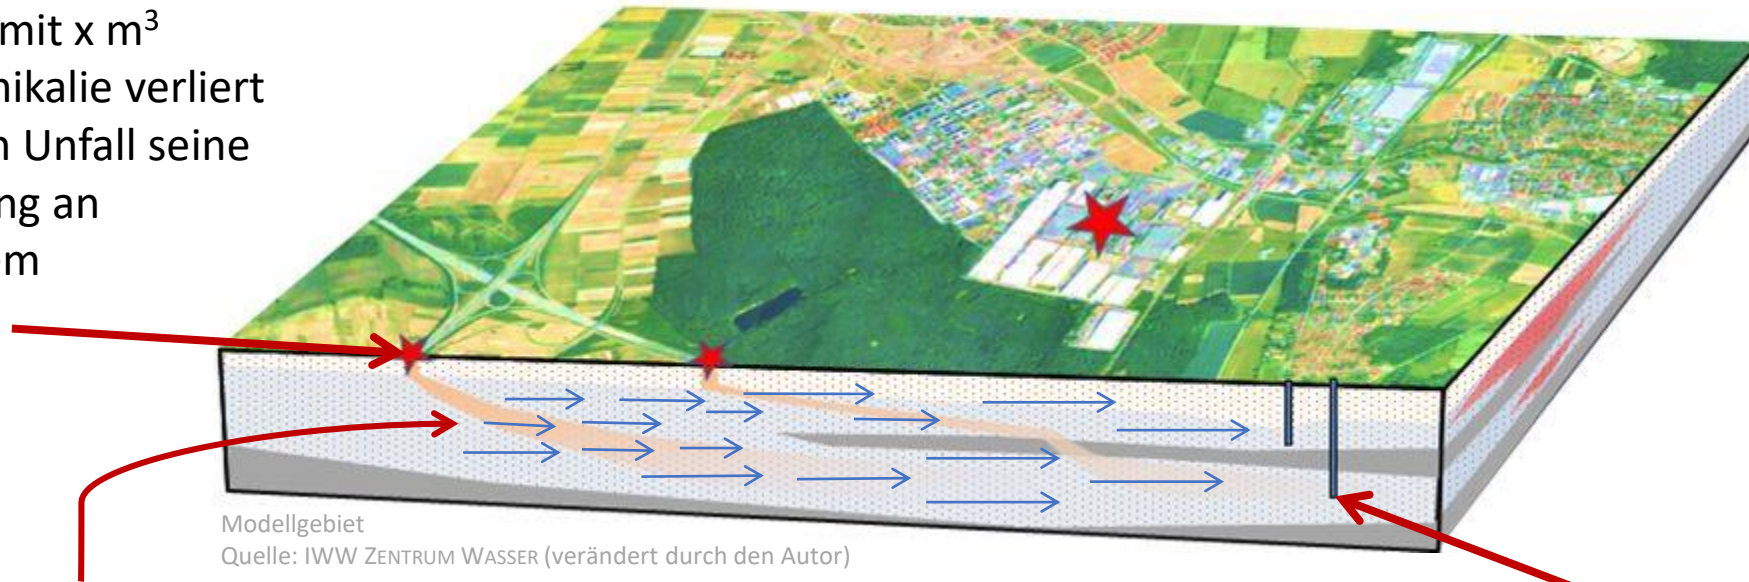


Beispielszenario zur Anwendung von Stofftransportmodellierung

Gegeben:

LKW mit $x \text{ m}^3$

Chemikalie verliert
durch Unfall seine
Ladung an
diesem
Ort.



Modellgebiet
Quelle: IWW ZENTRUM WASSER (verändert durch den Autor)

Grundwasserleiter:

Hydraulisch leitende Formation aus permeablen
Sedimenten wie Kies, Sand, Silt und einer
Wasserschicht über einer impermeablen Schicht
(oftmals bestehend aus Ton)

Fragestellung:

Kann man „voraussagen“, ob, und wenn ja, wann an diesem
Ort die Chemikalie in welcher Konzentration ankommt?

Methoden



Der Stofftransport kann durch die Lösung einer *hinreichend genau* beschreibenden Differentialgleichung modelliert werden.

Stofftransportgleichung

berücksichtigt in der Grundwassermodellierung: Diffusion, Advektion sowie Quellen/Senken

$$\frac{\partial c}{\partial t} = \nabla(\underline{D \cdot \nabla(c)}) + \underline{(-\nabla(v_A \cdot c))} + \underline{\sigma}$$

Substitution der Abstandsgeschwindigkeit v_A durch implizites Darcy-Gesetz: $v_A = \kappa \cdot \nabla(h)$ führt zu:

$$\frac{\partial c}{\partial t} = \nabla(D \cdot \nabla(c)) - \nabla(\kappa \cdot \nabla(h) \cdot c) + \sigma$$

$c = c(\vec{x}, t)$:= Konzentration, t := Zeitpunkt, D := Diffusionskoeffizient (konstant über Ort und Zeit), $v_A(\vec{x})$:= Abstandsgeschwindigkeit, $\kappa = \kappa(\vec{x})$:= Permeabilitätsfeld, $h = h(\vec{x})$:= Höhe am Ort \vec{x} , ∇ := Nabla-Operator, $\sigma = \sigma(\vec{x}, t)$:= Inhomogenität (Quelle/Senke)

Methoden




- Modellparameter sind häufig nicht stetig.
-> Stofftransportgleichung nicht analytisch lösbar
- Daher:
Numerische Lösung der Stofftransportgleichung
durch Approximation des Differentialquotienten

$$\frac{\partial c}{\partial t} \approx \frac{c^{t+1} - c^t}{\Delta t}$$

Einschrittverfahren zum Lösen von Anfangswertproblemen.

Es gibt verschiedene Lösungsverfahren

Aus Zeitlichen Gründen habe ich das einfachste (explizites Eulerverfahren) angewendet/implementiert.



Modellgebiet

Quelle: IWW ZENTRUM WASSER (verändert durch den Autor)

Methoden



- Solverimplementierung

$$\begin{aligned} \frac{c_{i,j}^{t+1} - c_{i,j}^t}{\Delta t} = & D_{i,j} \left(\frac{c_{i+1,j}^t - 2c_{i,j}^t + c_{i-1,j}^t}{(\Delta x_1)^2} + \frac{c_{i,j+1}^t - 2c_{i,j}^t + c_{i,j-1}^t}{(\Delta x_2)^2} \right) \\ & - c_{i,j}^t \left(\frac{\kappa_{i+1,j} - \kappa_{i-1,j}}{2\Delta x_1} + \frac{\kappa_{i,j+1} - \kappa_{i,j-1}}{2\Delta x_2} \right) \left(\frac{h_{i+1,j} - h_{i-1,j}}{2\Delta x_1} + \frac{h_{i,j+1} - h_{i,j-1}}{2\Delta x_2} \right) \\ & - \kappa_{i,j} \left(\frac{h_{i+1,j} - h_{i-1,j}}{2\Delta x_1} + \frac{h_{i,j+1} - h_{i,j-1}}{2\Delta x_2} \right) \left(\frac{c_{i+1,j}^t - c_{i-1,j}^t}{2\Delta x_1} + \frac{c_{i,j+1}^t - c_{i,j-1}^t}{2\Delta x_2} \right) \\ & + \sigma_{i,j}^t \end{aligned}$$

Animation der Lösung der Stofftransportgleichung
anhand zweier Beispiele auf Basis unterschiedlicher
Permeabilitätsfelder...



Methoden

- Automatisiertes Generieren von Trainingsdaten durch semistochastisch erzeugte Permeabilitätsfelder gekoppelt mit dem Solver.
 - Es wurde für jeden Fall die Lösung zum 3000sten Zeitschritt berechnet.
 - Instabile Lösungen wurden durch entsprechende Stabilitätskriterien (Neuman'sches Kriterium, Maximumsnorm) evaluiert und falls nötig verworfen.
 - Valide Lösungen wurden als Ausgabedateien (Permeabilitätsfeld und Konzentrationsfeld) im CSV-Format gespeichert.
 - Permeabilitätsfelder wurden zudem als PNG-Datei zu Visualisierungszwecken pro erzeugten Datensatz gespeichert.

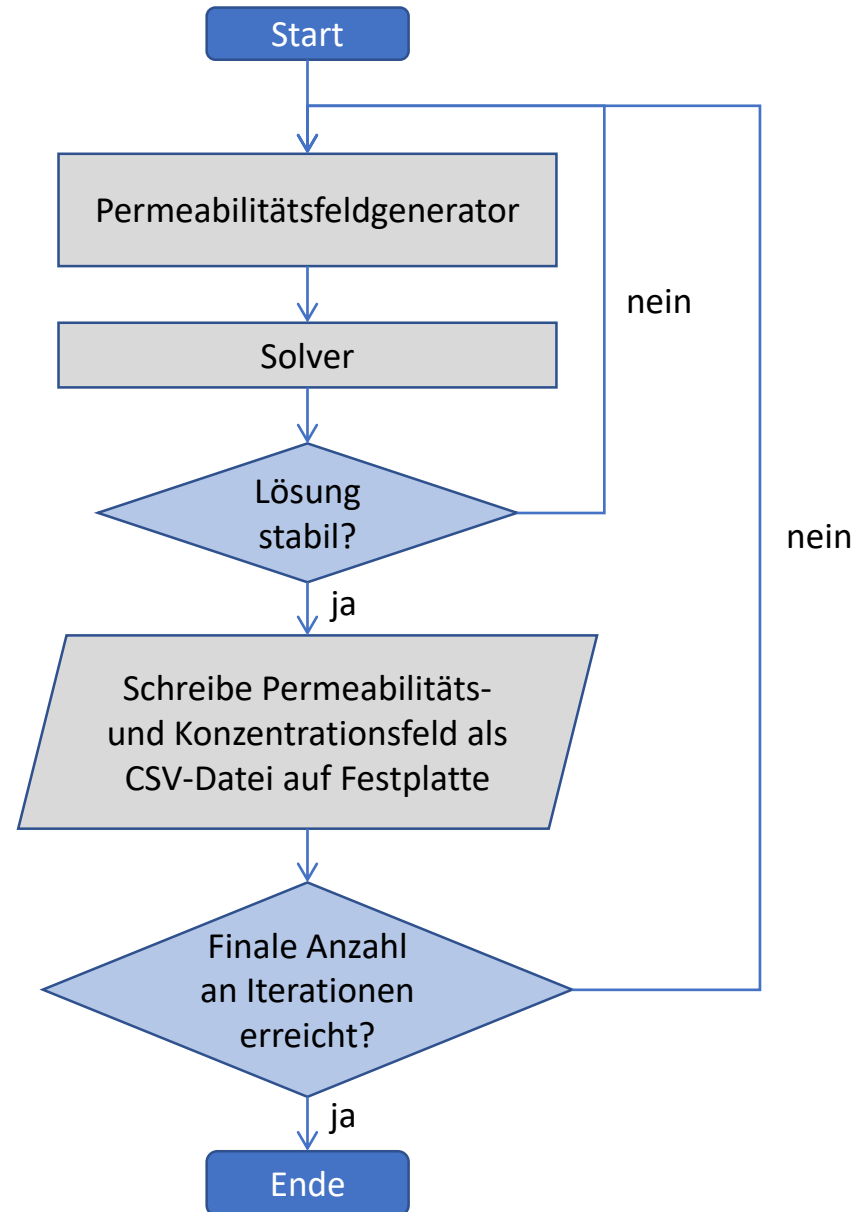
...Noch ein wenig Anschauliches dazu.

Methoden

Schema des Programmablaufs
zum Generieren der
Trainingsdaten.

Gerechnet wurde anfangs auf
zwei Raspberry Pi 4
-> 3 Wochen für 4677 so
erzeugte Datentupel.

...dann auf Desktop-Rechner
-> 6 h für weitere 3611
Datentupel.



Methoden



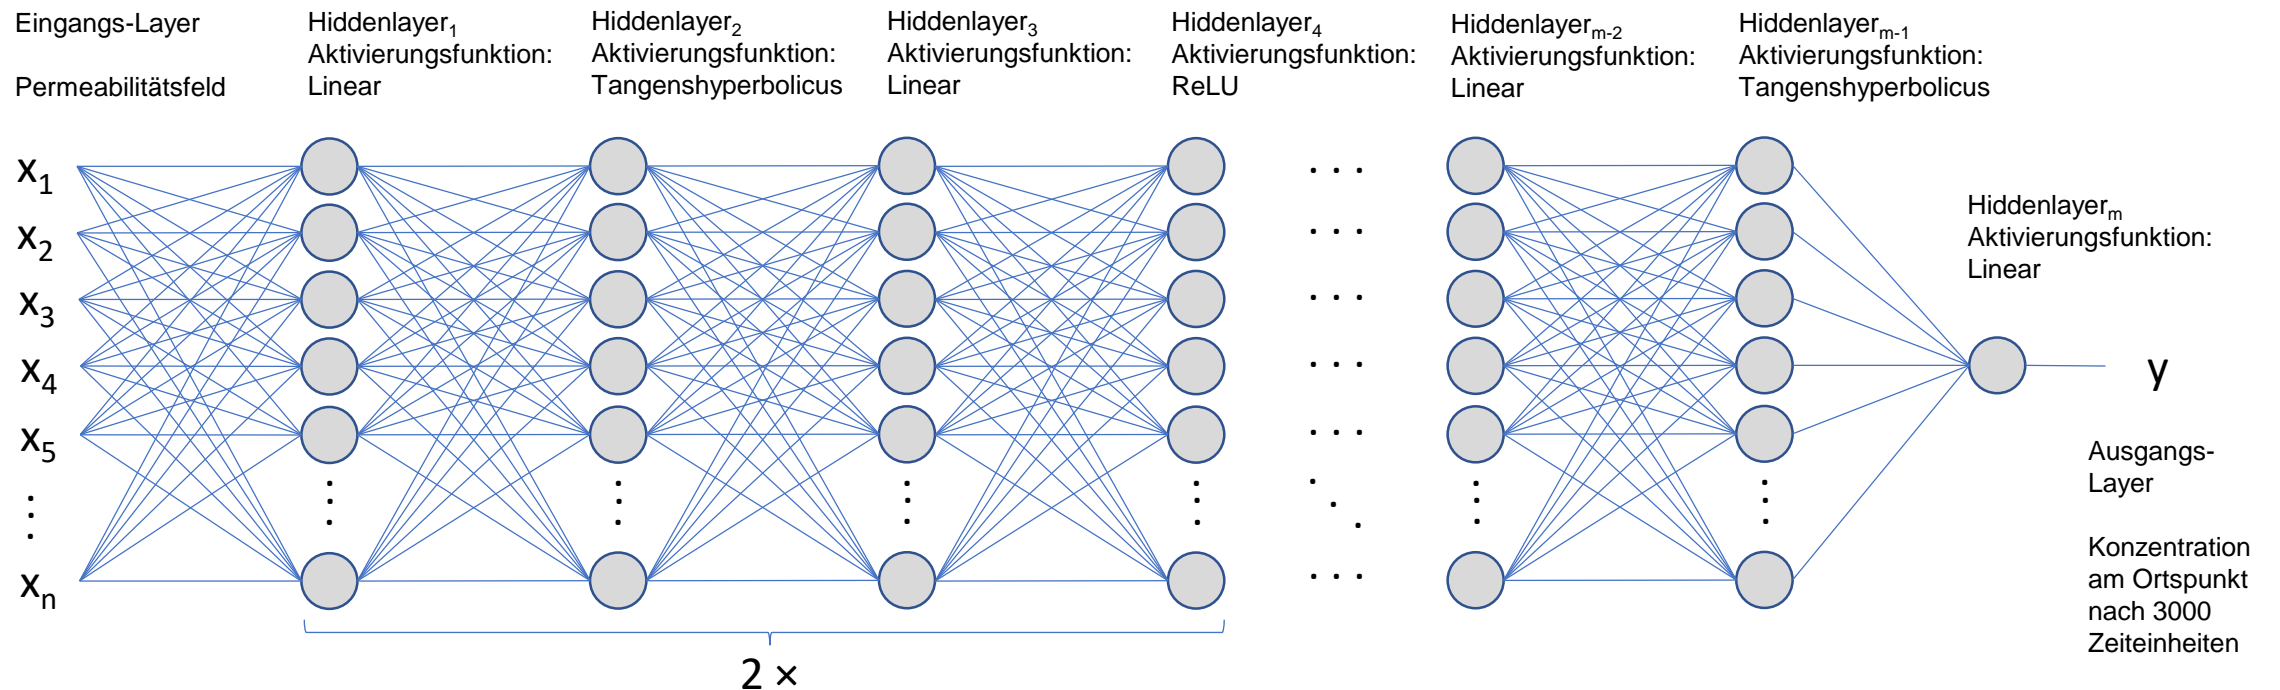
Das neuronale Netz

- PYTORCH als verwendetes Framework
- Gerechnet wurde final auf einer GPU (GeForce RTX 2060 mit 1920 Shader-Einheiten)
...dazu by the way ein kleiner Benchmark:
 - > ca. 6 mal schneller als auf Desktop-Rechner-CPU (i9 9900k, 16 Threads / @3.6 GHz)
 - > ca. 18 mal schneller als auf Laptop-CPU (i5, 8 Threads @1.6 GHz)
- Zwei Trainingsdatensätze zu 4677 und 8288 Lösungen wurden in des Modell einbezogen
- 2500 Eingabeneuronen (da 50×50 Gitterzellen)
- 11 Hiddenlayer mit unterschiedlichen Aktivierungsfunktionen
- Ein Ausgabeneuron (Konzentrationswert an der definierten Gitterzelle)
- Mehrere Modelle definiert durch unterschiedliche Orte wurden automatisiert gerechnet.

Methoden



Das künstlich neuronale Netz



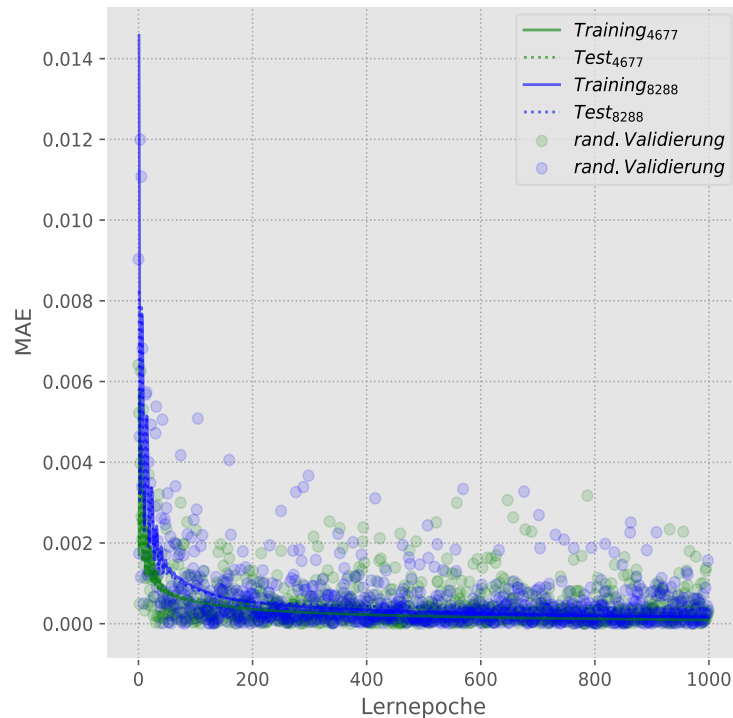
- klassisches Feedforeward-Netz
-> allen Neuronen sind mit den Neuronen der folgenden Schicht verbunden

Ergebnisse/Diskussion




Drei Modellergebnisse:
einziger veränderter Parameter ist die Gitterzellenkoordinate

Modelloptimierung zum Modell:
Gitterzelle@ $i = 10; j = 10$




Modellfehlerverhalten über den Lernzeitraum von 1000
Lernepochen an der Gitterzelle $i=10, j=10$

Modelloptimierung zum Modell:
Gitterzelle@ $i = 20; j = 20$



Modellfehlerverhalten über den Lernzeitraum von 1000
Lernepochen an der Gitterzelle $i=20, j=20$

Modelloptimierung zum Modell:
Gitterzelle@ $i = 30; j = 30$



Modellfehlerverhalten über den Lernzeitraum von 1000
Lernepochen an der Gitterzelle $i=30, j=30$